

Optimiser la gestion des données

Par Naziha BOUSSEMAHA




Sommaire

- Contexte
- Objectifs
- Technos et langages de programmations
- Datasets
- Process :
 - Exploration
 - Nettoyage
 - Jointure : Nouveau Dataframe cohérent
 - Calcul d'un KPI : le Chiffre d'affaires
- Analyse univariée sur la variable des prix :
 - Distribution des prix
 - Analyse des Outliers via 2 méthodes :
 - Méthode Interquartile
 - Méthode Z-score
 - Analyse complémentaire

Contexte

- ERP non relié au site des ventes en ligne :
 - Gestion des stocks complexe
 - Visibilité réduite des ventes sur le web



Objectifs



CMS



Technos et méthodologie de l'analyse

Technos



Dataset

3 Fichiers Excel



ERP.xlsx

- Solution de gestion e-commerce (stocks, commandes, prix)

WEB.xls

- CMS : système de gestion de contenu du site e-commerce

Liaison.xlsx

- Table d'associations entre les id de l'ERP et du CMS

Exploration des données

Package Missingno

L'ERP

	product_id	onsale_web	price	stock_quantity	stock_status
1					
825					


Dimensions :

- 825 lignes et 5 colonnes
- Aucune valeur manquante
- Chaque valeur est unique dans la clé « product_id »

Les liaisons

Dimensions :

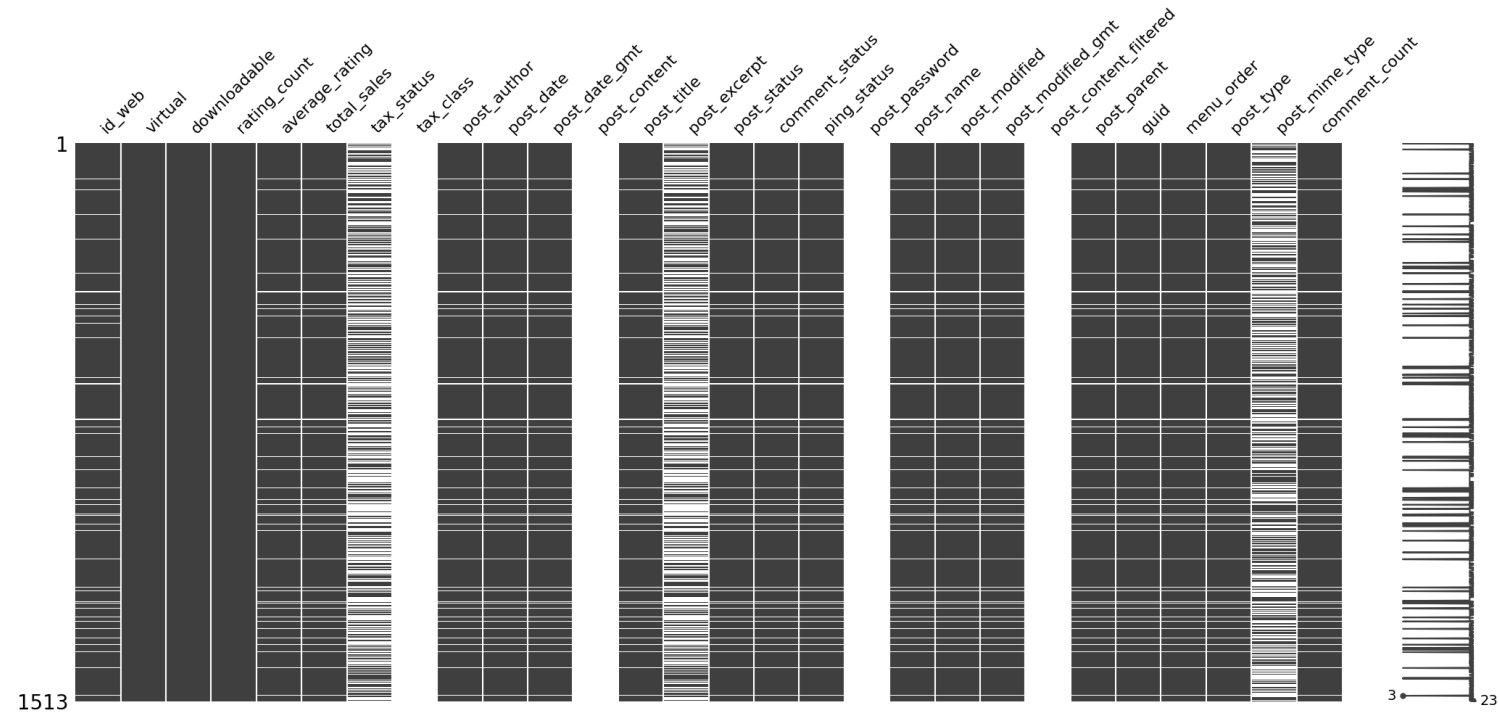
- 825 lignes et 2 colonnes
- Unicité de la clé
« product_id »
- Aucune valeur manquante
dans la variable
« product_id »
- 91 NaN dans la variable
« id_web » du CMS



Le CMS

Dimensions :

- 1513 lignes et 28 colonnes
- 1513 doublons
- Colonnes vides
- Chaînes de caractères dans la clé



Incohérences

- 1513 doublons
- Chaque « image/jpeg » a une clé identique à son produit
- Les données des images font redondances avec les données du produit
- 85 valeurs manquantes dans la clé avant filtrage
- Colonnes vides
- Chaînes de caractères dans la clé primaire « id_web »
- Nom de la clé primaire « sku » qui ne correspond pas à sa clé étrangère dans le fichier « Liaisons »

```
len(web_df.loc[web_df['id_web'].duplicated(keep=False),:])
```

✓ 0.0s

1513

```
comparison = web_df.loc[web_df['id_web'] == 16209]
comparison[['id_web', 'total_sales', 'post_name', 'tax_status', 'post_type', 'post_mime_type']]
```

✓ 0.0s

	id_web	total_sales	post_name	tax_status	post_type	post_mime_type
3	16209	6.0	maurel-cabardes-tradition-2017	taxable	product	NaN
13	16209	6.0	maurel-cabardes-tradition-2017	NaN	attachment	image/jpeg

```
nb_na = web_df.isnull().sum()
nb_na[nb_na>0]
```

id_web	85
average_rating	83
total_sales	83
tax_status	797
tax_class	1513
post_author	83
post_date	83
post_date_gmt	83
post_content	1513
post_title	83
post_excerpt	797
post_status	83
comment_status	83
ping_status	83
post_password	1513
post_name	83
post_modified	83

```
# Filtrer les chaînes de caractères
chaines = [str(val) for val in web_df['id_web'].unique() if isinstance(val, str)]
```

```
# Afficher la liste des chaînes de caractères
print(chaines)
```

✓ 0.0s

['bon-cadeau-25-euros', '13127-1']

sku

Vérification des valeurs

```
# Filtrer les chaînes de caractères
chaines = [str(val) for val in web_df['id_web'].unique() if isinstance(val, str)]

# Afficher la liste des chaînes de caractères
print(chaines)
```

✓ 0.0s

['bon-cadeau-25-euros', '13127-1']

```
# Filtrer les chaînes de caractères
chaines = [str(val) for val in liaisons_['id_web'].unique() if isinstance(val, str)]

# Afficher la liste des chaînes de caractères
print(chaines)
```

✓ 0.0s

['bon-cadeau-25-euros', '13127-1', '14680-1']

Valeurs communes
aux tables liaisons
et CMS

Nettoyage des données

Process de nettoyage

- ❑ Filtrer sur le « post_type » pour ne conserver que les
« Product »
- ❑ Suppression des 5 colonnes vides
- ❑ Suppression des 2 NaN dans la clé primaire « id_web »
avec la méthode `.dropna(subset=['id_web'])`
=> (Une clé primaire **DOIT** être unique et non nulle)

Relier les exports ERP et CMS

□ Jointure interne sur les clés
« product_id » et « id_web »




- ✓ Les exports sont reliés
- ✓ Le dataframe est uni et propre
- ✓ Nous obtenons **714** correspondances et **28** lignes

	product_id	onsale_web	price	stock_quantity	stock_status	id_web	virtual	downloadable	rating_count	average_rating	total_sales	tax_status	post_author	post_date	post_date_gmt	post_title	post_excerpt	post_status	comment_status	ping_status	post_name	post_modified	post_modified_gmt	post_parent	guid	menu_order	post_type	comment_count
1																												
714																												

Calcul du chiffre d'affaires

Key Performance Indicator

KPI : Le Chiffre d'affaires




- Chiffres d'affaires total est de **70 568,60 EUR** entre 2018 et 2020
- Les champagnes Gosset Grand Blanc et Grand Rosé représentent la part la plus importante du CA total, **soit +12%**

Analyse univariée

Le prix des produits

Dispersion des prix

- Moustache inférieure : de 5,20 à 14,10 EUR
- Moustache supérieure : de 42,18 à 84,10 EUR
- 84 EUR représente le seuil de l'écart interquartile
- 32 Outliers




Outliers

**Pour observer les valeurs extrêmes,
nous avons utilisé 2 méthodes :**

- l'écart Interquartile
- Z-score

Méthode Interquartile

Dispersion des Prix en fonction du seuil Interquartile




Méthode Z-Score

Cela donne une idée de la distance de chaque valeur par rapport à la moyenne en termes d'écart-type. Un Z-score positif entre 2 et 7 indique que la valeur est loin de la moyenne, ce qui peut indiquer une valeur atypique

Classement du Z-Score des Outliers




Boxplot du Z-Score



- Déterminer le seuil à partir duquel est considéré un outlier

Analyse complémentaire : Vins de prestige

Classement des meilleures Ventes parmi les Outliers



Conclusion

- Les outliers sont le résultat de fortes variations naturelles des prix entre des vins ordinaires et des vins de prestiges
- L'ERP est relié au site des ventes en ligne
- La gestion des stocks est facilitée
- Visibilité des ventes sur le web accessible à tous les services

