



Algorithme de détection automatique de faux billets



Sommaire

1. EDA

1.1 - Analyse descriptive

1.2 - Gestion des valeurs manquantes : Inférer par régression linéaire

1.2.1 - Choix du modèle : optimisation & performances

1.2.2 - Analyse des résidus : vérification des hypothèses

1.2.3 - Complétude des valeurs manquantes

2. Premier modèle prédictif avec technique d'apprentissage non supervisée : K-means

2.1 - Analyse en composantes principales

2.2 - Optimisation des paramètres

2.3 - Clustering & analyse des centroïdes

2.4 - Test & analyse de la performance

3. Second modèle prédictif avec technique d'apprentissage supervisée : Régression Logistique

3.1 - Régression logistique sans hyperparamètres : analyse des performances

3.2 - Optimisation de notre modèle : RFECV & GridSearchCV

4. Test du modèle de prédiction

Technos



NumPy



Pandas





matplotlib

1. EDA : Analyse explorato ire des données

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1500 entries, 0 to 1499
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype  
---  -
0   is_genuine   1500 non-null   bool    
1   diagonal     1500 non-null   float64 
2   height_left  1500 non-null   float64 
3   height_right 1500 non-null   float64 
4   margin_low   1463 non-null   float64 
5   margin_up    1500 non-null   float64 
6   length       1500 non-null   float64 
dtypes: bool(1), float64(6)
memory usage: 71.9 KB
```



	is_genuine	diagonal	height_left	height_right	margin_low	margin_up	length
0	True	171.81	104.86	104.95	4.52	2.89	112.83
1	True	171.46	103.36	103.66	3.77	2.99	113.09
2	True	172.69	104.48	103.50	4.40	2.94	113.16
3	True	171.36	103.91	103.94	3.62	3.01	113.51
4	True	171.73	104.28	103.46	4.04	3.48	112.54

	diagonal	height_left	height_right	margin_low	margin_up	length
count	1500.000000	1500.000000	1500.000000	1463.000000	1500.000000	1500.000000
mean	171.958440	104.029533	103.920307	4.485967	3.151473	112.67850
std	0.305195	0.299462	0.325627	0.663813	0.231813	0.87273
min	171.040000	103.140000	102.820000	2.980000	2.270000	109.49000
25%	171.750000	103.820000	103.710000	4.015000	2.990000	112.03000
50%	171.960000	104.040000	103.920000	4.310000	3.140000	112.96000
75%	172.170000	104.230000	104.150000	4.870000	3.310000	113.34000
max	173.010000	104.880000	104.950000	6.900000	3.910000	114.44000



1.1 Analyse descriptive



Les faux billets
présentent des
moyennes supérieures
sur les dimensions des
hauteurs et des marges



Test de normalité des données : Shapiro-Wilk

Variable : diagonal semble suivre une distribution normale (p-valeur = 0.32343590259552)
Variable : height_left semble suivre une distribution normale (p-valeur = 0.0509396530687809)
Variable : height_right semble suivre une distribution normale (p-valeur = 0.9806053638458252)
Variable : margin_low ne semble pas suivre une distribution normale (p-valeur = 2.8283876088209786e-24)
Variable : margin_up ne semble pas suivre une distribution normale (p-valeur = 0.000810406228993088)
Variable : length ne semble pas suivre une distribution normale (p-valeur = 7.863947037789753e-28)

1.1 Analyse descriptive



1.2 – Gestion des valeurs manquantes : Inférer par régression linéaire

➤ **37 valeurs manquantes au total :**


- 29 NaN dans les vrais billets

➤ **Variable cible :**

- 8 Nan dans les faux billets
- « margin_low »

➤ **Prédicteurs :**


- « diagonal », « height_left », « height_right », « margin_up », « length »



	valeurs non nulles	valeurs uniques	doublons	type de donnée	nombre de valeurs manquantes	pourcentage de valeurs nulles
colonne						
is_genuine	1500	2	0	object	0.000000	0.00
diagonal	1500	159	0	float64	0.000000	0.00
height_left	1500	155	0	float64	0.000000	0.00
height_right	1500	170	0	float64	0.000000	0.00
margin_low	1463	285	0	float64	0.024667	2.47
margin_up	1500	123	0	float64	0.000000	0.00
length	1500	336	0	float64	0.000000	0.00

1.2.1 – Choix du modèle : Optimisation & Performances

Observation de la linéarité entre les variables



Métrique		Train	Test
0	R2	0.471559	0.496208
1	MSE	0.231702	0.225424
2	RMSE	0.481355	0.474788

- Moyenne de l'erreur quadratique (MSE) est proche de 0 (exclusion d'overfitting)
- Test Durbin_Watson : pas d'autocorrélation des résidus

Modèle n°1

margin_low ~ length

R² : 46.87%

Modèle n°2

margin_low ~ height_right + height_left + margin_up + length

R² : 46.7%

Modèle n°3, meilleure performance

margin_low ~ diagonal + height_right + height_left + margin_up + length

R² : 47.2%

```

=====
OLS Regression Results
=====
Dep. Variable:      margin_low    R-squared:      0.472
Model:              OLS          Adj. R-squared:  0.469
Method:             Least Squares F-statistic:      207.7
Date:               Sat, 25 May 2024 Prob (F-statistic): 2.09e-158
Time:               21:57:33      Log-Likelihood: -804.71
No. Observations:   1170         AIC:              1621.
Df Residuals:       1164         BIC:              1652.
Df Model:            5
Covariance Type:    nonrobust
=====
               coef    std err          t      P>|t|      [0.025    0.975]
-----
const          29.8893     10.941     2.732     0.006     8.424    51.355
diagonal       -0.1451     0.047    -3.074     0.002    -0.238   -0.052
height_left     0.1546     0.051     3.045     0.002     0.055     0.254
height_right    0.2660     0.048     5.495     0.000     0.171     0.361
margin_up       0.2665     0.072     3.716     0.000     0.126     0.407
length         -0.3997     0.020   -19.626     0.000    -0.440   -0.360
=====
Omnibus:          54.041    Durbin-Watson:      2.005
Prob(Omnibus):    0.000    Jarque-Bera (JB):    67.134
Skew:             0.467    Prob(JB):            2.64e-15
Kurtosis:         3.710    Cond. No.            1.96e+05
=====
    
```

➤ Qualité de prévision assez médiocre : 47.2% de variance




➤ Très proche de zéro => modèle significatif

➤ Toutes les variables sont significatives < 5%

➤ Problème de colinéarité potentiel

éc	VIF	Factor	features	'IFs de chaque
1.001316	1.001316	1.466025	const	
1.011842	1.011842		diagonal	
1.143630	1.143630		height_left	
1.250358	1.250358		height_right	
1.406416	1.406416		margin_up	
1.603271	1.603271		length	

1.2.2 Analyse des résidus : Vérification des hypothèses



2 hypothèses invalidées

- ✓ Hétéroscédasticité confirmée par le test de Breüs-Pagan
- ✓ Normalité des données rejetée par le test de

Preuve significative d'homoscédasticité (p-value < 0.05 : 2.3716448342116843e-14)

Statistique de test de normalité des résidus (Kolmogorov-Smirnov) : 0.19132686171258778


P-value : 5.530402021193502e-38

Les résidus d'entraînement ne suivent pas une distribution normale.

- ✓ Poursuite de l'analyse
 - ✓ Moyenne suffisamment proche de 0
 - ✓ Échantillon suffisamment grand (1463)
 - ✓ Courbe « relativement en cloche »
 - ✓ Variables significatives < 5%
 - ✓ Modèle robuste et significatif


Moyenne des résidus sur le jeu d'entraînement : -2.6144328867070355e-15
Moyenne des résidus sur le jeu de test : 0.03385696783869508

1.2.3 – Complétude des valeurs manquantes




```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1500 entries, 0 to 1499
Data columns (total 7 columns):
#   Column          Non-Null Count  Dtype
---  -
0   is_genuine      1500 non-null  object
1   diagonal        1500 non-null  float64
2   height_left     1500 non-null  float64
3   height_right    1500 non-null  float64
4   margin_low      1500 non-null  float64
5   margin_up       1500 non-null  float64
6   length          1500 non-null  float64
dtypes: float64(6), object(1)
memory usage: 82.2+ KB
```

2. Premier modèle prédictif avec technique d'apprentissage non supervisée :




3.1 Analyse en composantes principales




- ❑ 60,24% de la variance capturée par les 2 axes principaux
- ❑ Pas de différences entre les données d'origines et après normalisation
- ❑ 1er axe représenté par : margin_low (corrélation positive) et length (corrélation négative)
- ❑ 2ème axe : fortement corrélé à « diagonal » Coeff. Corrélacion proche de 1

2.1 Analyse en composantes principales



Les faux billets ont des hauteurs et des marges supérieures à la moyenne !



3.2 Choix du k et Optimisation des paramètres sur le « training set »

```
n_clusters 2  
score k-means -5805.026596797184  
silhouette_score: 0.3425575415231918
```

```
n_clusters 3  
score k-means -5103.148636675269  
silhouette_score: 0.20935293849488237
```



```
n_clusters 4  
score k-means -4680.252849217826  
silhouette_score: 0.19574877528564172
```

```
n_clusters 5  
score k-means -4360.200851965393  
silhouette_score: 0.15685773528927915
```


```
n_clusters 6  
score k-means -4185.443546205042  
silhouette_score: 0.15319517912057729
```

Paramètres algorithme

- ✓ Séparation training/testing set : 80/20
- ✓ Algorithme K-means++,
n_clusters = 2
- ✓ n_init = « auto »
- ✓ Initialisation du Random_state
pour constance des résultats




Données non entrainées avec k-means



Zone d'incertitude avant
classification par l'algorithme k-
means



Données entrainées avec k-means Données du test




Il n'existe plus de zone
d'incertitude

3.3 – K-Means : Test & analyse de la performance

Performances du modèle avec 2 Clusters




Algorithme appliqué sur train



Rand score: 0.9688087294968029
Adjusted rand score: 0.9366134581986845
accuracy_score 0.9841666666666666
MIB: 0.8740066833488348
Adjusted MIB: 0.8739229387961293
FM score: 0.9723037747907189

Algorithme appliqué sur test set



Rand score: 0.9736008918617615
accuracy_score 0.9866666666666667
Adjusted rand score: 0.9469816764574738
MIB: 0.8958662114412843
Adjusted MIB: 0.8956005456730549
FM score: 0.9752062780873688

✓ Résultats
meilleurs sur
les données
de test





4. Second modèle prédictif avec technique d'apprentissag e supervisée : **Régression** **Logistique**





4.1 Régression logistique sans hyperparamètres : analyse des performances

Matrices de confusion du
modèle entraîné sur toutes
les variables




	precision	recall	f1-score	support
False	0.99	0.98	0.99	390
True	0.99	1.00	0.99	810
accuracy			0.99	1200
macro avg	0.99	0.99	0.99	1200
weighted avg	0.99	0.99	0.99	1200

	precision	recall	f1-score	support
False	1.00	0.98	0.99	110
True	0.99	1.00	0.99	190
accuracy			0.99	300
macro avg	0.99	0.99	0.99	300
weighted avg	0.99	0.99	0.99	300



4.2 – Optimisation de notre modèle : RFECV & GridSearchCV



✓ Suppression des variables les moins significatives par RFECV

✓ Meilleurs paramètres trouvés par « GridSearchCV » =
{
 'C': 1.0,
 'class_weight': 'balanced',
 'l1_ratio': 0,
 'max_iter': 500,
 'penalty': 'l1',
 'random_state': 42,
 'solver': 'saga'}

✓ Le solveur saga offre le meilleur compromis performances / efficacité computationnelle

✓ Train/test : 0.2
✓ Random_state : 42

Accuracy: 0.9966666666666667

Confusion Matrix:

```
[[109  1]
 [  0 190]]
```

Classification Report:

	precision	recall	f1-score	support
False	1.00	0.99	1.00	110
True	0.99	1.00	1.00	190
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

5 - Test du modèle de prédiction

➤ Résultats du test sur échantillon de production non étiqueté

Modèle de prédiction avec Régression Logistique fonctionnel

Import billet de
production
« fichier.csv »

Table test:

Pas de valeurs manquantes.
Pas de valeurs nulles.
Pas de doublons.
Format de donnees ok.

id	proba	labels_pred_reglog
B_1	9.991136e-01	True
B_2	3.382449e-04	False
B_3	9.999600e-01	True
B_4	2.034210e-07	False
B_5	2.232981e-03	False

- Livraison de notre modèle de
prédiction -

La régression logistique nous permet d'avoir pour
chaque billet, les probabilités que le billet soit vrai
ou faux

Conclusion