



Lapage

ANALYSE DES VENTES WEB

2021-2022



Par Naziha Boussemaha, Data Analyst

CONTEXTE ET OBJECTIFS

- ✓ mettre en lumière les différents indicateurs de performances et chiffres clés sur les ventes en lignes
- ✓ Mieux comprendre le comportement de nos clients en ligne pour comparer avec la connaissance acquise via les librairies physiques



Summary



- I. EDA
- II. Indicateurs et chiffres clés de Performances (KPI)
 - a. Evolution du chiffre d'affaires, taux de croissance et de variation
 - b. Courbe de Lorenz et coefficient de Gini : répartition du CA par client
 - c. Le « top 10 » des produits les mieux vendus
 - d. Le « top 10 » des produits les moins bien vendus
 - e. Analyses complémentaires



- III. Analyse comportementale des clients à travers cinq corrélations



- A. Test de normalité des données
 - a. la méthode « Kolmogorov Smirnov »
- B. Test statistique du Chi-2 pour vérifier :
 - a. La relation entre l'âge et le genre des clients
- C. Calcul du coefficient de corrélation de Pearson pour vérifier la relation :
 - a. entre l'âge et le montant total des achats
 - b. entre l'âge et la fréquence d'achat
 - c. entre l'âge et la taille du panier moyen
- D. Test statistique ANOVA pour vérifier la relation :
 - a. entre l'âge des clients et la catégorie



- IV. Synthèse et piste de réflexions

Technos et méthodologie de l'analyse



Pandas



NumPy

matplotlib

plotly



I. EXPLORATION DES DONNEES (EDA)



EDA

	Clients_df	Products_df	Transactions_df	Actions/méthodes
Importation	clients_df = pd.read_csv('customers.csv', sep=';')	products_df = pd.read_csv('products.csv', sep=';')	Transactions_df = pd.read_csv('Transactions.csv', sep=';')	pd.read_csv
Dimensions	8621 rows and 3 columns	3286 rows and 3 columns	687534 rows and 4 columns	.shape()
Typage et format	- client_id => object - sex => object - birth => integer	- id_prod => object - Price => float - categ => integer	- id_prod => object - date => object - session_id => object - client_id => object	Conversion de la date au format datetime et heure en <i>format</i> ='%Y-%m-%d %H:%M:%S.%f' 24h => 00h
Valeurs uniques	8621	3286	3265	.nunique()
Valeurs manquantes	0	0	0	.isna().sum()
Doublons	0	0	687516	.duplicated() => Faux doublons de 'id_prod' dans Transactions_df. 1 produit peut être acheté plusieurs fois
Jointures	PK='client id'	PK='id prod'	FK='id_prod' et FK='client_id' Table	Jointure interne Nouveau dataframe 'merging final'



Dataframe :
Merging_final

EDA

Variables	Remarques
Price	Aucune valeur négative
Year	Incomplétude des années 2021 et 2023. • 2021 : janvier et février sont manquants • 2023 : de mars à décembre sont manquants
Création de colonnes supplémentaires pour notre analyse	• age • year • month • day

II. INDICATEURS ET CHIFFRES CLÉS DE PERFORMANCES (KPI)



a. Evolution du chiffre d'affaires et Taux de croissance

Comparaison des deux périodes :


- août 2021 à février 2022
- août 2022 à février 2023



+ **11,05%** d'augmentation du CA entre **août 2021 et février 2022**



- **09,83%** de baisse du CA entre **août 2022 et février 2023**



Variations du chiffre d'affaires entre 2021 et 2022




- ✓ L'année 2022 est en nette progression par rapport à 2021 **+23,66% par rapport à 2021**



- ✓ Néanmoins, des **résultats négatifs** sont relevés en **septembre, novembre et décembre**

Taux de variation mensuel entre CA 2021 et CA 2022




Répartition du CA : la courbe de Lorenz

Inégalité significative dans la répartition du chiffre d'affaires

Coefficient de Gini = 0,4411

- ❑ 50% du CA est concentré sur 78% des clients
- ❑ 7% du CA est concentré sur 1% des clients

Courbe de Lorenz du chiffre d'affaires




Composition de la clientèle

- 4 clients B2B parmi la clientèle




Top 10 des meilleurs clients 2021 et 2022




Répartition du Chiffres d'affaires par catégorie

(données 2021-2022)

B2C



B2B




Répartition du Chiffres d'affaires par genre


(données 2021-2022)



Chiffre d'affaires par genre chez les B2B



Chiffre d'affaires par genre chez les B2C




Répartition des prix par catégorie

Le prix moyen d'un livre de
catégorie 2 est de :

76,21 €

**Soit 3,5 fois plus élevé que le
prix moyen d'un livre de
catégorie 1 et 7,5 fois plus élevé
qu'un livre de catégorie 0**




- *Quel profil de client achète cette catégorie ?*


REPARTITION DU CA PAR TRANCHE D'AGE




- La clientèle âgée de 18 ans achète le plus



- Les 30-55 ans sont ceux qui produisent le plus de CA




Clients âgés entre 30 et 49 ans sont la plus représentée



Saisonnalité : Fréquences horaires des commandes chez les B2B

Fréquence d'achats par heure pour chaque client




B2B : Le « top 10 » des catégories de livres




La **catégorie 2** est celle qui émet le plus de bénéfices

B2B: Top 10 des catégories de livres les plus rentables (2021-2022)




La **catégorie 1** est celle qui se vend en plus grand nombre


B2B: Top 10 des catégories de livres les mieux vendus (2021-2022)




B2B : les 10 plus mauvaises ventes



B2B : Les livres les moins rentables




« les flops » : Produits les moins bien vendus




B2B : Part du chiffre d'affaires par catégorie


parts du CA par catégorie : c_1609




parts du CA par catégorie : c_6714



parts du CA par catégorie : c_3454




parts du CA par catégorie : c_4958




Part du CA des 4 grands clients par rapport au CA global



Part du CA des 4 meilleurs clients par rapport au CA total





III. ANALYSE COMPORTEMENTALE DES CLIENTS



A. Test de normalité : Méthode « Kolmodorov Smirnov »




Les variables « price » et « âge » ne suivent pas une distribution gaussienne



B. Test du Chi2 : relation entre l'âge & la catégorie

a. Existe-t-il une relation entre la catégorie de livre acheté et le genre ?



Graphiquement nous ne pouvons pas confirmer ou infirmer l'hypothèse nulle qu'il n'existe pas de relation entre le sexe et la catégorie du produit, d'où le test du chi2

Test du Chi2 : Résultats statistiques

Hypothèses :

H0 : Il n'existe pas de relation entre la catégorie de livre et le genre du client

H1 : Il existe une relation entre ces 2 variables

Tableau de
contingence

sex	f	m
categ		
0	189974	193162
1	109545	106770
2	15764	17600

Test Chi2


Tableau des fréquences
attendues

```
Test du chi-2 : 155.1688828516694
P-valeur : 2.0207156603352204e-34
Degrés de liberté : 2
Tableau des fréquences attendues :
[[190887.17474775 192248.82525225]
 [107773.11243412 108541.88756588]
 [ 16622.71281812  16741.28718188]]
```

Le test statistique du khi-carré permet de rejeter l'hypothèse nulle selon laquelle il n'y a pas de relation entre les variables catégoriques. (p-valeur < 0,05)


=> Cela suggère qu'il y a une association statistiquement significative entre les variables 'sex' et 'categ'.

COEFFICIENT DE CORRÉLATION DE PEARSON





a. Existe-t-il une corrélation entre l'âge et le montant total des achats ?

- Relation linéaire inverse marquée entre l'âge et le montant total des achats. Il existe une corrélation très forte entre l'âge des clients et le chiffre d'affaires total engendré par client, le coefficient de Pearson à -0.88 confirme que plus un client est jeune, plus le total d'achats est élevé.




b. Existe-t-il une corrélation entre l'âge des clients et la fréquence d'achat ?

- Le coefficient de corrélation obtenu **de -0,58** indique une **corrélation négative modérée** entre l'âge et la fréquence d'achat. Cela suggère qu'à mesure que l'âge augmente, la fréquence d'achat a tendance à diminuer, et vice versa, bien que cela ne soit pas nécessairement une relation causale.





c. Existe-t-il une corrélation entre l'âge des clients et la taille du panier moyen ?

- Nous obtenons une corrélation négative modérée entre l'âge des clients et la taille du panier moyen.
- Lorsque l'âge augmente, la taille du panier moyen tend à diminuer, mais cela ne signifie pas nécessairement une relation linéaire parfaite.



D. Test Statistique ANOVA

a. Existe-t-il une relation entre l'âge des clients et la catégorie des livres achetés ?



IV. SYNTHÈSE ET PISTES DE REFLEXIONS



Synthèse et pistes de réflexions

- 2 types de clients : BtoB et BtoC
- 1 Client sur 4 est une femme parmi la clientèle B2B
- Equilibre des genres dans la clientèle B2C
- +23,66% de CA entre 2021 et 2022
- En 2022, 7,36% de notre chiffre d'affaires provient de 4 clients B2B
- Le taux de variation du CA est positif en 2022 par rapport à 2021 même si on note que les périodes des rentrées scolaires et fêtes de fin d'année sont en nette décroissance par rapport à 2021
- Inégalité de la mixité chez la clientèle B2B
- - 14.73% du chiffre d'affaires entre février 2022 et février 2023
- il y a une association statistiquement significative entre le genre et la catégorie
- Forte relation inverse entre l'âge des clients et le montant total des achats : A mesure que l'âge augmente, le montant total des achats tend à diminuer.
- Il y a une corrélation négative modérée entre l'âge et la fréquence d'achat. Cela suggère qu'à mesure que l'âge augmente, la fréquence d'achat a tendance à diminuer, et vice versa.
- corrélation négative modérée entre l'âge des clients et la taille du panier moyen : Lorsque l'âge augmente, la taille du panier moyen tend à diminuer
- les moyennes d'âge varient de manière significative entre les différentes catégories